

Method of UWB Indoor Location Based on Improved Extreme Learning Machine in Case of Anchor Abnormity*

MIAO Xiren, FAN Jianwei, JIANG Hao*, CHEN Jing, HUANG Xinyu

(School of Electrical Engineering and Automation, Fuzhou University, Fuzhou Fujian 350100, China)

Abstract: In the UWB indoor positioning system, the anchors are extremely vulnerable to interference, which affects the accuracy, stability and reliability of the positioning system. When the interference is strong, data of anchors will fluctuate abnormally, and the accurate positioning cannot be completed. In order to solve the positioning problem of abnormal anchor of UWB indoor positioning system, this paper proposes a positioning model based on particle swarm optimization extreme learning machine(PSO-ELM), which can achieve high-precision positioning in the case of abnormal anchor. The positioning model uses two-way ranging based on time of flight(TW-TOF) to collect the distance between the tag and the anchors, and the indoor positioning model is established by extreme learning machine (ELM). Meanwhile, in order to overcome the disadvantages of ELM algorithm, particle swarm optimization(PSO) is introduced to optimize the hidden layer weight and threshold parameters of the ELM. Experimental results show that: under normal conditions of anchors, the average positioning accuracy of PSO-ELM positioning model can reach 0.03 m, which is improved by 73% than the traditional TOA positioning algorithm. In the case of abnormal anchors, the average positioning accuracy can reach 0.04m, solving the problem that the positioning system cannot complete the normal positioning when abnormal anchors.

Key words: UWB; indoor positioning; abnormal anchor; extreme learning machine; particle swarm optimization

EEACC: 7230

doi: 10.3969/j.issn.1004-1699.2020.10.013

基站异常情况下基于改进极限学习机的 超宽带室内定位方法*

缪希仁, 范建威, 江 灏*, 陈 静, 黄新宇

(福州大学电气工程与自动化学院, 福建 福州 350100)

摘 要: 在超宽带(UWB) 室内定位系统中, 定位基站极易受到干扰, 从而影响定位系统的准确性、稳定性和可靠性, 干扰较强时, 会造成基站数据异常波动, 无法完成准确定位。为解决 UWB 室内定位系统基站异常情况的定位问题, 本文提出了一种基于粒子群优化的极限学习机(PSO-ELM) 定位模型, 实现在定位基站发生异常情况下的高精度定位。该定位模型利用双边测距(TW-TOF) 采集标签和基站的距离, 运用极限学习机(ELM) 建立室内定位解算模型; 引入粒子群算法(PSO) 优化极限学习机的隐含层权值和阈值参数, 以克服 ELM 算法存在的缺点。实验结果表明: 在基站正常情况下, PSO-ELM 定位模型平均定位精度可达 0.03 m, 相比于传统 TOA 定位算法, 精度提高了 73%; 同时在基站异常情况下, 平均定位精度可达 0.04 m, 有效解决了当定位系统基站发生异常情况时无法完成正常定位的问题。

关键词: 超宽带; 室内定位; 基站异常; 极限学习机; 粒子群算法

中图分类号: TN98; TH89

文献标识码: A

文章编号: 1004-1699(2020) 10-0457-10

近年来, 随着无线传感技术的发展, 无线室内定位技术得到了广泛的应用, 超宽带(UWB) 是一种脉

冲无线通信技术, 是目前室内定位领域的研究热点之一^[1-2]。UWB 凭借着其带宽的独特优势, 在军

项目来源: 国家自然科学基金青年科学基金项目(61703105, 61703106); 福建省高校杰出青年科研人才计划项目(601934)

收稿日期: 2020-07-05 修改日期: 2020-09-28

事、物联网等各个领域都有着广阔的应用,成为最具有发展前景的无线通信技术之一。在室内定位的应用中,UWB 技术可以实现厘米级的定位精度,并具有良好的抗多径干扰和衰弱的性能以及具有较强的穿透能力,而被广泛用于室内机器人导航、室内人员定位等等^[3-4]。但由于室内环境复杂多变,UWB 通信信号极易受到遮挡而产生非视距误差(Nonlight-of-sight, NLOS),在较强干扰时,数据会发生异常波动,基本无法完成室内定位,甚至会造成严重事故。如何减小 NLOS 误差或者基站数据发生异常的情况下保证 UWB 定位的精度成为研究的热点之一^[5]。

目前,在无线传感网络(WSN)中,一般采用基于测距的方式实现高精度的定位^[6]。常见基于测距的 UWB 室内定位方法主要有基于到达角度(Angle of arrive, AOA),基于到达时间(Time of flight, TOF),基于到达时间差(Time difference of arrival, TDOA)等,一般在用于 UWB 室内定位时,常采用上述其中一种或多种进行组合的定位方法^[7],但精度及稳定性都存在一定问题,更多的研究人员在上述的定位方法上引进滤波等算法,以提高系统的精度和稳定性。Jose M. Huerta 等人提出了一种基于粒子滤波和无迹卡尔曼滤波的跟踪策略来估计 UWB 室内定位中的 NLOS 误差,极大程度提高了定位的精度^[8]。Gao 等人则是利用双向到达时间测距(TWR),提出了一种鲁棒最小二乘公式(RLS),将时钟偏置和旋转时间作为干扰参数,采用二阶锥松弛方法近似拟合,提高定位的精度^[9];高端阳等人提出了一种鲁棒无迹卡尔曼滤波的室内定位算法,通过引入代价函数,自适应修正观测方差,建立鲁棒机制,提高 UWB 定位系统的适应能力,一定程度上提高了 UWB 室内定位精度^[10];刘韬提出了一种基于自适应卡尔曼滤波算法的 UWB 定位方法,在 UWB 的距离模型上,利用视距环境构造抗差因子抑制非视距造成的误差,使用 Sage-Husa 滤波对系统噪声实时修正,最终利用卡尔曼滤波进行位置解算,提高的测距和定位系统的精度^[11];Wang 等人提出了一种基于迭代扩展卡尔曼滤波器(IEKF)连续更新观测值的协方差和后验状态方法。构造后验分布的边缘分布并迭代优化,抑制了复杂环境下对 UWB 定位的影响,实验证明该方法相比于标准 EKF 和鲁棒 EKF 具有更高精度的定位结果^[12];Liu 等人则是提出了一种 EKF 和视觉的 UWB 室内定位方法,先利用 EKF 算法实现 UWB 的粗略室内定位,再结合单目视觉的方法,实现高精度的 UWB 室内定位^[13];Cao 等人针对测距过程的噪声分布,采用高斯混合

模型(GMM)重新估计测距结果,并在交互多模型(IMM)结构下使用两个并行的变分贝叶斯自适应卡尔曼滤波器(VBAKF)平滑高斯混合模型的结果,分别消除视距误差和非视距误差,最后再根据 IMM-VBAKF 的结果,利用扩展卡尔曼滤波(EKF)来确定目标节点的位置,该定位方法提高了 UWB 室内定位的精度^[14]。

近年来,为了提高 NLOS 环境的 UWB 定位精度,PCA、BPNN、SVM 等机器学习算法也被逐渐应用^[15]。Zhang 等人提出了基于网格搜索的核支持向量机和主成分分析的室内定位算法,可以有效减小室内定位的误差^[15];Yongyang Lv 等人对传统的 BP 算法进行改进,引进智能优化算法,提出了基于 GA-PSO-BP 的混合定位模型,Yongyang Lv 先验证了 PSO-BP 算法对室内定位系统的有效性,最后再加入遗传算法(GA)实现混合定位,提高了室内定位的精度^[16]。然而,上述对 UWB 定位方法的研究都是基于定位系统基站正常工作下实现的,若 UWB 定位系统某基站信号出现较大干扰,会造成基站与标签之间的测距信号异常,测距数据会发生较大波动,往往无法完成正常定位。

针对 UWB 基站异常定位方法的研究,国内外研究还处于探索阶段。合肥工业大学方文浩等人针对 UWB 井下定位系统,提出了一种基于区域判定的方法,采用非对称双边双向测距(ADS-TWR)抑制测距误差,引入区域异常自检和区域校正机制,提高系统的稳定性,保证系统在 UWB 定位基站发生异常时能实现井下定位,定位精度在 15 cm 左右^[6];Josef Kulmer 使用 DecaWave 公司的 UWB 芯片,评估定位系统的瞄准线和反射多径分量的信噪比,提出一种基于多路辅助的 UWB 定位方法,仅需一个基站便能实现定位,有效解决了多基站系统基站数据异常的问题,但该方法的定位精度仅仅只能达到 0.5 m^[17];曾庆化等人提出将 UWB 定位与惯导系统相结合的室内定位方法,将定位数据与微惯导数据经卡尔曼滤波处理,修正位置,一定程度上避免了 UWB 基站出现问题时的定位问题^[18]。就目前的研究情况,容忍 UWB 基站异常的定位方法,其定位精度还有待提高。

为解决基站异常情况下,UWB 室内定位系统无法正常定位的关键问题,本文提出了一种基于粒子群算法优化极限学习机(PSO-ELM)的 UWB 室内定位方法,该方法基于双向飞行时间测距(TW-TOF)得到基站和标签之间距离,并运用粒子群算法改进的极限学习机(PSO-ELM)建立 UWB 定位模型替代

传统的三边定位模型; 当某一基站数据发生异常波动情况时, 该定位模型可实现快速融合替换, 保证 UWB 系统的定位精度。

1 考虑基站异常的 UWB 定位原理

基站异常情况下基于改进极限学习机的 UWB 室内定位方法针对 UWB 定位系统基站出现异常的情况下进行精准的室内定位。系统的工作原理和框架如图 1 所示。工作原理主要分为三部分: 测距数据采集、建立 ELM 定位模型、PSO 优化 ELM 参数。

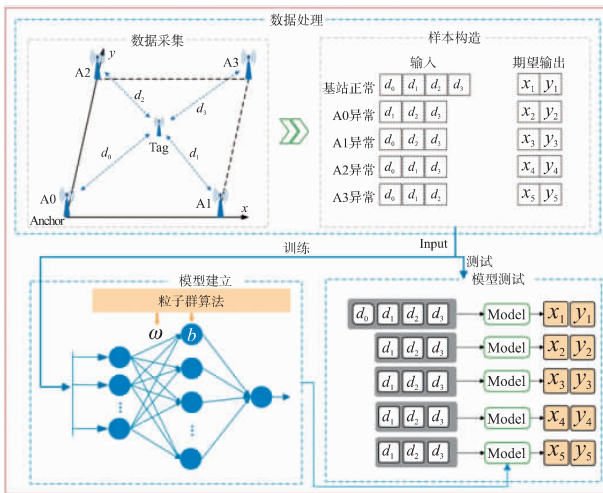


图 1 考虑基站异常的 UWB 定位原理

当 UWB 室内定位系统的某一基站出现异常情况时, 该基站与定位标签之间的通讯会受到严重影响, 造成测距出现极大的误差, 难以实现准确的室内定位。本文提出的定位方法针对 UWB 定位基站出现异常情况进行室内定位, 通过采集异常情况下非异常基站与定位标签的距离数据, 将距离数据作为特征量利用 ELM 网络构建室内定位模型, 并采用 PSO 优化 ELM 网络的隐含层权值和阈值参数。

假设在室内环境中布设有 n 个已知坐标的 UWB 定位基站, 基站与定位标签之间相互感知, 标签将 UWB 脉冲发送到基站, 每一个定位标签共有 n 条通讯链路, 根据基站与标签之间相互通讯可测得两者之间的距离, 为了减小基站与标签之间由时钟不同步造成的测距误差, 本文使用基于双向飞行时间的测距方法获得基站与标签的距离。定位标签与每个基站以轮询的方式完成测距, 由各个基站将测距数据发送到主基站 A0, 主基站通过串口将测距数据汇总上传至上位机。将测距数据分为训练数据和测试数据, 给定训练数据的位置标签, 构建 ELM 定位模型, 对训练数据进行训练, 将 ELM 网络输出的均方误差作为 PSO 的适应度函数, 对 ELM 的权值

和阈值寻优, 优化定位模型。离线训练 $n+1$ 个定位子模型, 包括 1 个全基站定位子模型和 n 个单基站异常的子定位模型。将 $n+1$ 个模型进行融合定位。若基站未出现异常情况, 则将所有基站与定位标签的距离数据作为该模型的输入, 得到期望的位置输出; 若检测到某一基站出现信号异常, 则将其余 $n-1$ 个未出现异常的基站的测距数据作为融合模型的输入, 模型内部将自动选择单基站异常的子定位模型进行求解, 从而实现当某一基站出现信号异常时精准的室内定位。

2 极限学习机

基于 PSO-ELM 的 UWB 室内定位系统主要利用极限学习机构建定位模型。传统前馈神经网络具有训练速度较慢、易陷入局部最优、学习率的选择较敏感等缺点, 南洋理工大学黄广斌教授^[19]在对单隐藏层前馈神经网络 (Single-hidden Layer Feedforward Neural Network, SLFN) 的研究过程中发现 SLFN 的学习能力不会受到网络的输入权值和隐藏层节点阈值的影响, 提出了一种新的单隐藏层前馈神经网络, 即极限学习机 (Extreme Learning Machine, ELM)。该算法的输入权值和隐藏层节点参数随机选取, 仅需要通过求解隐藏层输出权值的伪逆矩阵得到输出权值矩阵, 即可完成神经网络的训练过程, 整个过程仅需要一次计算就可得到网络参数, 大大降低了计算量。实验证明, 该算法依然具有良好的泛化能力, 拟合精度高, 被广泛应用于各个领域^[20]。

ELM 网络结构如图 2 所示, 有 n 个输入神经元, L 个隐藏层神经元, m 个输出神经元, 隐藏层的激活函数为 $G(\cdot)$, 假设有 N 个任意的样本 (X_i, t_i) , 其中 $X_i = [x_{i1}, x_{i2}, \dots, x_{in}]^T \in R^n$ 是模型的输入样本数据, $t_i = [t_{i1}, t_{i2}, \dots, t_{im}]^T \in R^m$ 是期望输出, 则图 2 的神经网络可以表示为:

$$\sum_{i=1}^L \beta_i G(W_i \cdot X_j + b_i) = o_j, j=1, \dots, N \quad (3)$$




图 2 ELM 网络结构图

式中: $\mathbf{W}_i = [w_{i1}, w_{i2}, \dots, w_{in}]^T$ 为输入权重, β_i 为输出权重, b_i 是第 i 个隐藏层神经元的偏置。 $\mathbf{W}_i \cdot \mathbf{X}_j$ 表示 \mathbf{W}_i 和 \mathbf{X}_j 的内积, o_j 表示第 j 个样本的输出。

当隐藏层节点足够时, ELM 可以逼近任何连续函数, 为使得 ELM 的具有更好的泛化能力, 通常隐藏层神经元 L 应该大于输入神经元 n , 单隐层神经网络学习的目标是使得输出的误差最小^[17], 即使得:

$$\sum_{j=1}^N \|\mathbf{o}_j - \mathbf{t}_j\| = 0 \quad (4)$$

即存在 β_i, \mathbf{W}_i 和 b_i , 使得:

$$\sum_{i=1}^L \beta_i G(\mathbf{W}_i \cdot \mathbf{X}_j + b_i) = \mathbf{t}_j, j=1, \dots, N \quad (5)$$

式(5)使用矩阵可以表示为:

$$\mathbf{H}\beta = \mathbf{T} \quad (6)$$

式中: \mathbf{H} 为隐藏层神经元的输出, β 为输出权重, \mathbf{T} 为期望输出。

$$\mathbf{H} = \begin{bmatrix} G(w_1x_1+b_1) & G(w_2x_1+b_2) & \cdots & G(w_Lx_1+b_L) \\ G(w_1x_2+b_1) & G(w_2x_2+b_2) & \cdots & G(w_Lx_2+b_L) \\ \vdots & \vdots & \ddots & \vdots \\ G(w_1x_N+b_1) & G(w_2x_N+b_2) & \cdots & G(w_Lx_N+b_L) \end{bmatrix}_{N \times L} \quad (7)$$

$$\beta = \begin{bmatrix} \beta_1^T \\ \beta_2^T \\ \vdots \\ \beta_L^T \end{bmatrix}_{L \times m}, \quad \mathbf{T} = \begin{bmatrix} T_1^T \\ T_2^T \\ \vdots \\ T_N^T \end{bmatrix}_{N \times m} \quad (8)$$

为了能训练单隐藏层神经网络, 希望得到 $\hat{\mathbf{W}}_i$, \hat{b}_i 和 $\hat{\beta}_i$, 使得:

$$\|\mathbf{H}(\hat{\mathbf{W}}_i, \hat{b}_i) \hat{\beta}_i - \mathbf{T}\| = \min_{\mathbf{W}, b, \beta} \|\mathbf{H}(\mathbf{W}_i, b_i) \beta_i - \mathbf{T}\| \quad (9)$$

式中: $i=1, \dots, L$, 这等价于最小化损失函数

$$E = \sum_{j=1}^N \left[\sum_{i=1}^L \beta_i G(\mathbf{W}_i \cdot \mathbf{X}_j + b_i) - \mathbf{t}_j \right]^2 \quad (10)$$

在 ELM 神经网络中, 一旦输入权重 \mathbf{W}_i 和隐藏层偏置 b_i 被随机确定, 则隐藏层的输出矩阵 \mathbf{H} 就被唯一确定^[19,21], 训练过程则可以转化为求解一个线性系统 $\mathbf{H}\beta = \mathbf{T}$, 因此输出权重 β 的最小二乘解则可以通过式(11)确定:

$$\hat{\beta} = \mathbf{H}^+ \mathbf{T} \quad (11)$$

式中: \mathbf{H}^+ 是矩阵 \mathbf{H} 的 Moore-Penrose 广义逆, 且 β 的最小二乘解是唯一的。相较于传统前馈神经网络, ELM 保证了学习精度, 具有良好的泛化性能, 速度更快。

3 PSO 优化 ELM 定位模型

受鸟类捕食行为的启发, 美国 Kennedy 等人提出了一种仿生优化算法, 即粒子群算法^[22] (Particle Swarm Optimization, PSO), PSO 由于算法简单, 容易实现, 立刻引起了相关领域学者们的广泛关注, 形成一个研究热点, 目前已广泛应用于函数优化、神经网络训练、模式分类、模糊控制等领域, 取得了较好的效果^[23]。该算法的主要思想: 在 D 维的问题目标搜索空间, 随机生成一定规模的群体作为问题搜索空间的有效解, 假设群体有 m 个粒子, 每个粒子有初始速度 v_i , 初始位置 x_i , 根据粒子的速度和位置向量以及适应度函数可计算出每个粒子的适应度值 F_i 。通过迭代, 粒子更新自己的速度和位置, 并根据粒子的适应度值更新每个个体的最优位置 $Pbest_i$ 和群体最优 $Gbest_i$, 再通过 $Pbest_i$ 和 $Gbest_i$ 不断更新粒子速度和位置, 从而让粒子在搜索空间中不断探索, 得到全局最优解。粒子根据式(13)更新位置和速度:

$$v_{id}^{k+1} = w \times v_{id}^k + c_1 \times rand_1^k \times (Pbest_{id}^k - x_{id}^k) + c_2 \times rand_2^k \times (Gbest_d^k - x_{id}^k) \quad (12)$$

$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1} \quad (13)$$

式中: w 是惯性权重, 表示粒子继承上一步迭代粒子的速度的能力; $\mathbf{v}_i^k = (v_{i1}^k, v_{i2}^k, \dots, v_{iD}^k)$ 、 $\mathbf{x}_i^k = (x_{i1}^k, x_{i2}^k, \dots, x_{iD}^k)$ 分别代表粒子 i 在第 k 次迭代中的速度向量和当前位置向量; $Pbest_{id}^k$ 是粒子 i 在第 k 次迭代中第 d 维的位置; $Gbest_d^k$ 是整个种群在第 k 次迭代时全局最优的位置; c_1 和 c_2 是学习因子, 或称加速系数, 分别调节向 $Pbest$ 和 $Gbest$ 方向飞行的最大步长, 合适的 c_1 和 c_2 既可加快收敛又不易陷入局部最优。 $rand_1$ 和 $rand_2$ 是介于 $[0, 1]$ 之间的随机数, 增加了粒子飞行的随机性。

在 ELM 神经网络训练中, 隐藏层权值和阈值是随机产生, 可能会导致回归效果不佳和稳定性不足, 可以利用 PSO 的全局搜索能力对神经网络的隐藏层权值和阈值求取最优解。本文采用训练样本的期望输出和拟合输出的均方误差 (Mean Squared Error, MSE) 作为适应度函数, MSE 的值越小, 定位模型的效果最优。适应度函数如下:

$$Fit = \frac{1}{m} \sum_{i=1}^m (y_i - \tilde{y}_i)^2 \quad (14)$$

式中: y_i 表示训练样本的期望值, \tilde{y}_i 表示训练样本的拟合值。本次实验中, 采用 PSO-ELM 算法流程如图 3 所示。

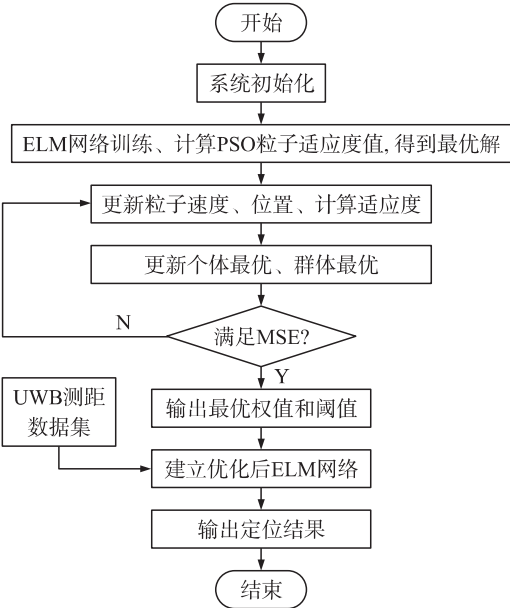


图 3 PSO-ELM 算法流程图


4 实验结果与分析

本文在常见的 UWB 室内定位环境下进行模型训练和实验测试, 讨论了 PSO-ELM 定位模型的静态定位性能和动态定位性能, 并分析了在不同基站发生异常情况下, 模型的定位性能, 最后将 PSO-ELM 定位模型与其他定位算法进行对比, 以验证本文所提出的基于 PSO-ELM 的室内定位模型的有效性。

4.1 实验环境与数据集

本文实验硬件采用基于 DecaWave 公司的 DWM1000 的定位模块, 模块控制器为 STM32F1 系列, 模块最大测距范围可以达到 100 m。本次实验选择 5 m×5 m 的室内环境作为定位实验区域, 定位系统如图 4 所示。定位区域 4 个角落分别布置 4 个定位基站, 依次标记为 A0、A1、A2 和 A3, 其中 A0、A1 和 A2 位于同一平面, 高度设置为 1.5 m, A3 与其余基站不在同一平面, 这里将 A3 高度设置为 1 m。

在实验过程中, 需采集定位标签与 4 个定位基站之间的距离数据作为定位算法数据集, 其中采集定位区域均匀分布的 672 个定位点作为模型的训练集, 即每隔 0.2 m 采集一个数据点; 另外分别采集 85 个均匀分布点的数据作为定位模型测试集, 用以测试定位模型的静态准确性; 采集标签在实验区域的一条矩形运动轨迹作为测试集测试定位模型的动态定位性能, 为了验证本文提出的 PSO-ELM 定位模型在定位基站发生异常下的有效性, 实验中需要模拟基站出现异常时的数据波动, 本次实验中采用人体近距离遮挡基站的方式模拟定位基站异常情况。



(a) 定位系统示意图



(b) 实验场景

图 4 室内定位系统

4.2 定位系统静态定位性能分析

由于在实验中布设 4 个定位基站, 所以采集到的数据集有 4 个特征, 即 ELM 神经网络的输入神经元为 4 个; 定位模型输出为平面二维坐标, 即 ELM 输出层神经元个数为 2; 隐藏层神经元个数设置为 200; PSO 的参数设置如表 1 所示。

表 1 PSO 算法参数设置

参数名称	参数大小
种群规模	50
权重最大值	0.8
权重最小值	0.4
加速度因子	1.5

计算每个测试点的均方根误差 (Root Mean Squared Error, RMSE)、 x 轴与 y 轴的平均误差和最大误差, 计算结果如表 2 所示, 基站正常情况测试点拟合结果如图 5 所示, RMSE 变化曲线如图 6 所示, 基站异常情况测试 RMSE 变化曲线如图 7 所示。

表 2 静态定位测试结果/m

性能指标	基站正常	A0异常	A1异常	A2异常	A3异常
RMSE 均值	0.03	0.05	0.04	0.04	0.03
RMSE 最大值	0.05	0.11	0.08	0.07	0.08
x 轴平均误差	0.02	0.04	0.03	0.03	0.03
x 轴最大误差	0.04	0.11	0.10	0.05	0.07
y 轴平均误差	0.02	0.04	0.04	0.03	0.02
y 轴最大误差	0.05	0.07	0.06	0.06	0.06




图 5 模型测试结果




图 6 基站正常 RMSE 变化曲线




图 7 基站异常 RMSE 变化曲线

可以看出,在基站正常的情况下,测试点 RMSE 均值达到 0.03 m,在 x 轴和 y 轴两个方向的位置误差均能控制在 0.05 m 以内,较好的实现了高精度室内定位。在各个基站发生异常的情况下,定位模型对 A0 异常情况的处理性能略劣于对其余 3 个基站发生异常的情况,这是由于 A0 基站是定位系统中的主基站,A0 发生异常对系统的影响相对来说会强于其余 3 个基站;从表 2 可以看到,基站发生异常时 PSO-ELM 定位模型处理结果, RMSE 均值均在 0.05 m 以内,在各方向的位置误差基本也能处理在 0.10 m 以下。

上述测试表明本文提出的 PSO-ELM 定位模型在基站正常或者异常处理的静态准确性均满足 UWB 室内定位系统高精度的定位要求。

4.3 定位系统动态定位性能分析

为了进一步探究 PSO-ELM 定位模型的动态定位性能,在实验定位区域对标签的运动轨迹进行测试,标签的起点坐标为 (1, 1),运动过程为:先平行于 y 轴正方向运动至 (1, 3),后向平行于 x 轴正方向

运动至 (3, 3),再平行于 y 轴运动至 (3, 1),最后平行于 x 轴运动回到起点。基站正常情况下动态测试结果如图 8 所示,动态过程 x 方向位置误差和 y 方向位置误差变化如图 9 所示,基站出现异常情况动态测试结果分别如图 10、图 11 所示。




图 8 基站正常情况测试轨迹



(a) 基站正常动态过程 x 方向误差变化(b) 基站正常动态过程 y 方向误差变化

图 9 基站正常动态过程误差变化

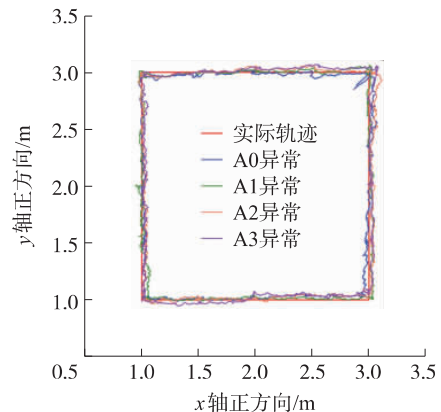


图 10 基站发生异常情况测试轨迹




图 11 基站异常动态过程误差变化

根据图 8~图 11 动态测试结果可知,在基站正常情况下,使用 PSO-ELM 定位模型拟合的运动轨迹基本贴近实际运动轨迹,在 x 轴和 y 轴方向的位置误差在 0.05 m 以内,定位误差最大的地方发生在运动过程的第二个拐角处,这是由于在运动过程中,拐弯是处于比较复杂的运动情况,标签与基站的测距误差相对会比较大,加之在第二个拐角是距离主基站 A0 最远处,标签的运动过程的测距误差也会增大;在基站发生异常的情况下,PSO-ELM 依旧能够将 x 方向和 y 方向的位置误差控制在 0.08 m 以内,同样也是在第二个拐角处误差相对较大,对比各个基站发生异常时 PSO-ELM 定位模型的处理效果,在主基站 A0 发生异常下,测试的误差相对较大,尤其是在第二个拐角处。因此,使用 PSO-ELM 定位模型在基站正常以及异常情况下都具有良好的动态处理效果,基本满足 UWB 定位系统高精度的定位要求。

4.4 不同算法静态定位性能对比

为了验证本文提出的 PSO-ELM 定位模型的在静态定位准确性上的优越,在实验中采用相同的测试数据分别经过 TOA 三边定位、ELM 定位模型、Elman 神经网络定位模型^[24]、最小二乘支持向量机 (LSSVM) 定位模型^[25]和、广义回归神经网络 (GRNN) 定位模型^[26]和 PSO-ELM 定位模型进行位置解算,其中 TOA 三边定位算法采用最小二乘法结算定位坐标。将每种算法的测试结果进行对比,分别计算测试点的 RMSE 和 x 轴与 y 轴的平均位置误差,不同算法测试点的误差计算如表 3 所示,基站正

常测试样本的 RMSE 变化曲线如图 12 所示,基站异常测试结果如图 13 所示。

表 3 不同定位算法精度对比 单位: m

算法	基站情况	RMSE 均值	RMSE 最大值	x 轴平均误差	y 轴平均误差
TOA	基站正常	0.11	0.23	0.09	0.10
	A0 异常	1.21	4.43	0.88	0.82
	A1 异常	1.05	4.23	0.75	0.78
	A2 异常	1.02	4.21	0.73	0.75
	A3 异常	0.12	0.25	0.10	0.10
ELM	基站正常	0.08	0.16	0.05	0.05
	A0 异常	0.14	0.59	0.10	0.09
	A1 异常	0.14	0.53	0.09	0.09
	A2 异常	0.12	0.43	0.09	0.08
	A3 异常	0.13	0.38	0.08	0.10
LSSVM	基站正常	0.06	0.10	0.04	0.05
	A0 异常	0.07	0.16	0.05	0.06
	A1 异常	0.07	0.16	0.05	0.05
	A2 异常	0.07	0.19	0.06	0.05
	A3 异常	0.10	0.19	0.07	0.06
GRNN	基站正常	0.04	0.08	0.02	0.03
	A0 异常	0.05	0.15	0.03	0.04
	A1 异常	0.05	0.16	0.05	0.04
	A2 异常	0.04	0.13	0.05	0.03
	A3 异常	0.04	0.13	0.04	0.03
Elman	基站正常	0.10	0.20	0.06	0.07
	A0 异常	0.10	0.31	0.07	0.08
	A1 异常	0.11	0.30	0.06	0.06
	A2 异常	0.10	0.35	0.06	0.07
	A3 异常	0.09	0.39	0.06	0.06
PSO-ELM	基站正常	0.03	0.05	0.02	0.02
	A0 异常	0.04	0.08	0.04	0.04
	A1 异常	0.04	0.08	0.03	0.04
	A2 异常	0.04	0.07	0.03	0.03
	A3 异常	0.03	0.08	0.03	0.02




图 12 基站正常情况不同算法 RMSE 变化曲线

根据表 3 和图 12 可知,在基站正常情况下,使用 TOA 定位算法, RMSE 均值为 0.11 m,最大值为 0.23 m;采用机器学习的各种定位模型相比于 TOA 定位算法,总体精度有一定的提高, RMSE 均值可以达到 0.10 m;虽然 ELM 和 Elman 定位模型在定位精度上总体优于 TOA 定位算法,但是在某些测试点依然会出

现 TOA 定位优于 ELM 和 Elman 的现象,而 LSSVM、GRNN 以及 PSO-ELM 定位模型在所有的测试点定位精度均优于 TOA 定位算法,其中 PSO-ELM 定位模型性能最优,其定位精度 RMSE 均值可以达到 0.03 m,最大值仅为 0.05 m,相比于 LSSVM 模型和 GRNN 模型,PSO-ELM 定位模型定位精度也有大幅度的提升。

根据测试结果可以看出,基站 A0、A1 和 A2 发生异常时 TOA 定位算法基本无法完成正常的室内定位,而在基站 A3 发生异常情况时,对定位系统的影响并不大,这是由于 TOA 定位只需要 3 个相同高

度的基站即可完成定位,A3 在 TOA 中主要起辅助作用;若采用 ELM、Elman、LSSVM 以及 GRNN 等定位模型,在任一基站异常时,都能完成精准的室内定位,机器学习算法的模型可以将 RMSE 均值保持在 0.20 m 以内,若使用 PSO-ELM 定位模型,其在基站异常下的定位精度相比于其余机器学习定位算法精度大幅度提升,测试点的 RMSE 均值可以达到 0.04 m 以内。综合上述实验可知,经过 PSO 优化后的 ELM 定位模型具有更好的泛化能力,在基站正常和异常的静态定位准确性均优于其余定位算法。

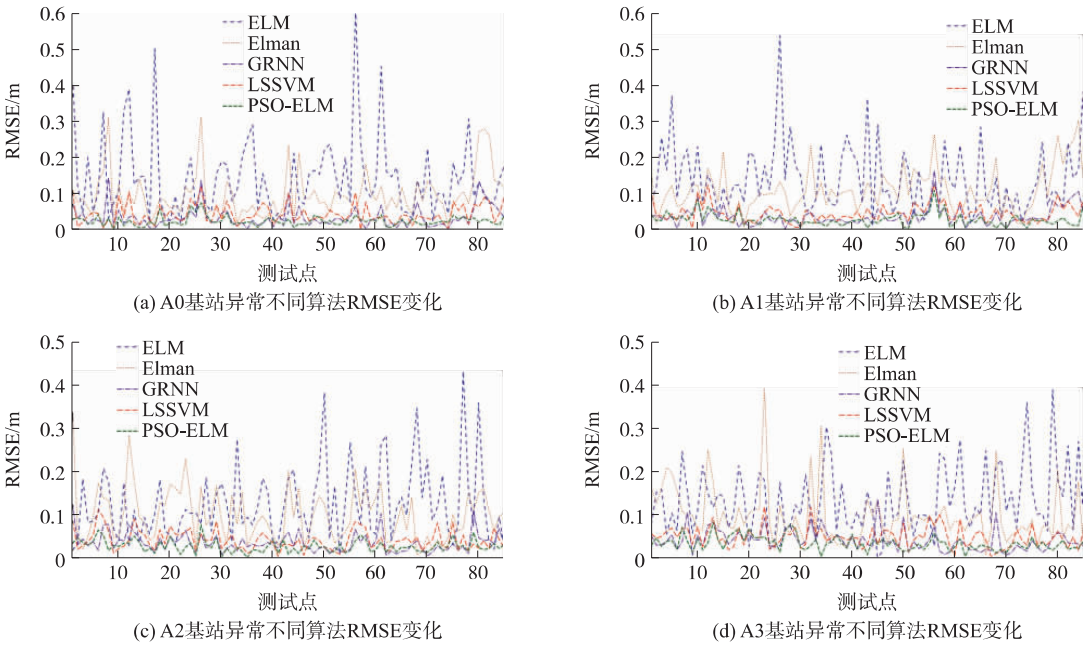


图 13 基站异常不同算法 RMSE 变化

为了对比较不同算法的时间复杂度,本文对比在基站正常情况下,各个算法的训练时间和测试时间(实验配置为: i5 处理器,1.8 GHz,8G 内存),对比结果如表 4 所示。

表 4 不同算法时间复杂度对比 单位: s

不同算法	训练时间	测试时间
TOA	—	0.008
ELM	0.039	0.006
Elman	1.325	0.011
LSSVM	0.117	0.015
GRNN	0.038	0.010
PSO-ELM	5.048	0.006

由可以看出,本文提出的 PSO-ELM 定位算法在模型训练过程中需要 PSO 算法对 ELM 神经网络的参数迭代寻优,因此训练时间相对较长。模型训练完毕,在实际测试过程中,ELM 网络的参数已经固定,便可充分发挥其单隐藏层的优势,测试时间都优于其他定位算法。

4.5 不同算法动态定位性能对比

最后,探究 PSO-ELM 定位模型动态定位性能的优越性,将标签在实验区域的一条矩形运动轨迹数据分别经过 TOA 三边定位、ELM 定位模型、Elman 定位模型、GRNN 定位模型、LSSVM 定位模型和 PSO-ELM 定位模型进行处理,处理结果分别如图 14、图 15 所示。

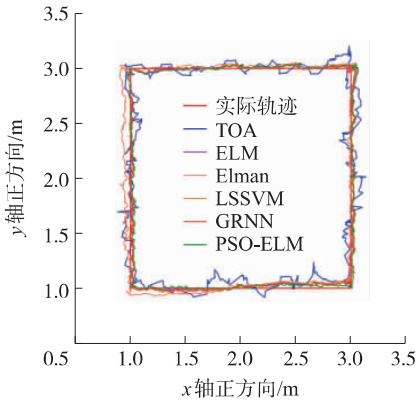


图 14 基站正常不同算法运动轨迹测试

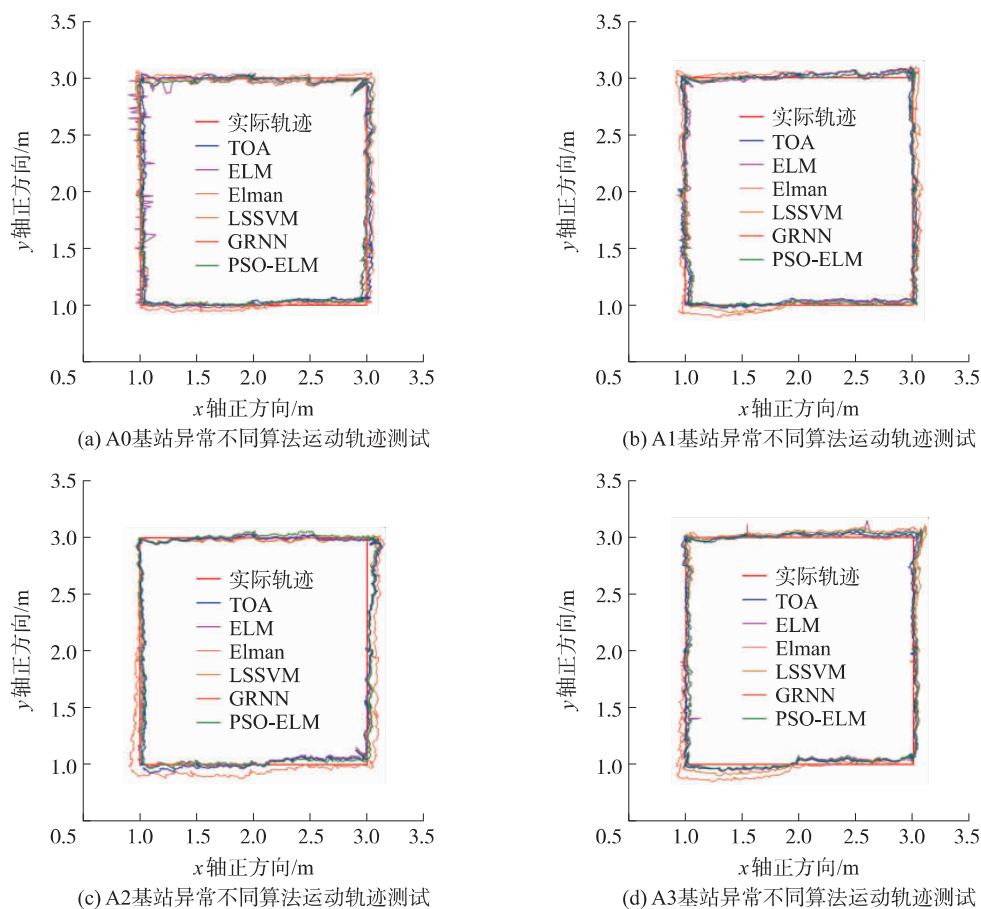


图 15 基站异常不同算法运动轨迹测试

观察图 14 可知,在基站正常情况下,TOA 定位算法对运动过程的处理波动性较大,虽然运动轨迹大致贴合实际运动轨迹,但是波动较大,在拐角点的处理也不够优秀,鲁棒性不足;采用 ELM、Elman、LSSVM、GRNN 和 PSO-ELM 算法处理时,总体误差相对较小,波动性不大,在拐角的处理也优于 TOA 算法,其中,PSO-ELM 定位模型处理效果最贴近实际运动轨迹,鲁棒性最强。在基站出现异常情况时,这里将 PSO-ELM 的处理效果与其余机器学习定位模型对比,根据图 15 各个基站出现异常情况的处理效果对比,相比于 ELM、Elman、LSSVM 和 GRNN 等定位算法,PSO-ELM 定位模型对运动轨迹处理效果相对有所提升,在运动过程的拐弯时,测距误差相对会更大,此时 PSO-ELM 定位模型所表现出来的优越性更加明显。因此,综合上述实验,PSO-ELM 定位模型的动态定位性能优于其余 5 中定位算法。

5 结论

在 UWB 室内定位系统中,各个基站极易受到外界因素的影响而造成测距数据异常波动,这会使定位系统的准确性、稳定性和可靠性都受到影响。本文在充分考虑到定位系统基站可能发生异常的情

况下,提出一种基于粒子群优化的极限学习机定位模型(PSO-ELM),通过对称双向测距获取各个基站与标签的距离数据,利用 ELM 神经网络训练建立室内定位模型,并针对 ELM 存在的缺点使用 PSO 优化网络的隐藏层权值的阈值,不仅实现了 UWB 定位系统在基站正常情况下的精准定位,也能够实现在某一基站数据发生异常下的准确定位,实验结果表明:在基站正常情况下,ELM 算法、Elman 算法等机器学习在大部分测试点的定位性能优于 TOA 三边定位算法,但也存在某些测试点 TOA 定位算法优于其他算法的现象,因此采用 ELM 算法和 Elman 等算法不具有普遍性;本文提出的 PSO-ELM 定位算法不论在定位的静态准确性还是动态性能均优于 TOA 定位算法、ELM 算法、Elman 算法、LSSVM 算法和 GRNN 算法,平均定位精度可达 0.03 m,相比于常用的 TOA 定位算法,定位精度提高了 73%。而在基站发生异常情况下,传统 TOA 定位算法无法完成正常定位,本文提出的 PSO-ELM 定位算法在基站异常情况下平均定位精度可达 0.04 m,相比基站正常情况定位精度并未明显下降,解决了当定位系统基站发生异常情况时无法完成正常定位的问题,具有较强的实用性,是一种高精度的室内定位算法。在

实际应用中,无人机室内定位、室内人员高精度定位等方面都可以得到广泛的应用。

参考文献:

- [1] Kok M, Hol J D, Schon T B. Indoor Positioning Using Ultrawideband and Inertial Measurements [J]. IEEE Transactions on Vehicular Technology, 2015, 64(4) : 1293-1303.
- [2] Arias-De-Reyna E. A Cooperative Localization Algorithm for UWB Indoor Sensor Networks [J]. Wireless Personal Communications, 2013, 72(1) : 85-99.
- [3] Li S, Li G, Wang L, et al. A three-Dimensional Robust Ridge Estimation Positioning Method for UWB in a Complex Environment [J]. Advances in Space Research, 2017, 60(12) : 2763-2775.
- [4] 杨海,李威,张永,等. 复杂环境下基于 SINS/UWB 的容错组合定位技术研究 [J]. 仪器仪表学报, 2017(9) : 93-101.
- [5] Óscar Belmonte-Fernández, Puertas-Cabedo A, Joaquín Torres-Sospedra, et al. An Indoor Positioning System Based on Wearables for Ambient-Assisted Living [J]. Sensors, 2016, 17(1) : 36.
- [6] 方文浩,陆阳,卫星. 基于区域判定的超宽带井下高精度定位 [J]. 计算机应用, 2018, 38(7) : 1989-1994.
- [7] Irahauten Z, Nikookar H, Klepper M. A Joint ToA/DoA Technique for 2D/3D UWB Localization in Indoor Multipath Environment [C] //International Conference on Communications(ICC), Ottawa, ON, 2012.
- [8] Huerta J M, Vidal J, Giremus A, et al. Joint Particle Filter and UKF Position Tracking in Severe Non-Line-of-Sight Situations [J]. IEEE Journal of Selected Topics in Signal Processing, 2009, 3(5) : 874-888.
- [9] Gao S, Zhang S, Wang G, et al. Robust Second-Order Cone Relaxation for TW-TOA-Based Localization with Clock Imperfection [J]. IEEE Signal Processing Letters, 2016, 23(8) : 1047-1051.
- [10] 高端阳, 李安, 傅军, 周鑫. 基于鲁棒无迹卡尔曼滤波的无线室内定位算法 [J]. 中国惯性技术学报, 2018, 26(6) : 768-772.
- [11] 刘韬, 徐爱功, 隋心. 基于自适应抗差卡尔曼滤波的 UWB 室内定位 [J]. 传感技术学报, 2018, 31(4) : 567-572.
- [12] Wang Y, Li X, Khoshelham K, et al. Robust Iterated Extended Kalman Filter Algorithm for Foot-Mounted Inertial Measurement Units/Ultrawideband Fusion Positioning [J]. Journal of Applied Remote Sensing, 2019, 13(2) : 024510.
- [13] Liu F, Zhang J, Wang J, et al. An UWB/Vision Fusion Scheme for Determining Pedestrians' Indoor Location [J]. Sensors, 2020, 20(4) : 1139-1158.
- [14] Cao B, Wang S, Ge S, et al. A Novel Mobile Target Localization Approach for Complicate Underground Environment in Mixed LOS/NLOS Scenarios [J]. IEEE Access, 2020, 8: 96347-96362.
- [15] Zhang L, Li Y, Gu Y, et al. An Efficient Machine Learning Approach for Indoor Localization [J]. 中国通信, 2017, 14(11) : 141-150.
- [16] Lv Y, Liu W, Wang Z, et al. WSN Localization Technology Based on Hybrid GA-PSO-BP Algorithm for Indoor Three-Dimensional Space [J]. Wireless Personal Communications, 2020(2) : 1-18.
- [17] Kulmer J, Hinteregger S, Grosswindhager B, et al. Using DecaWave UWB Transceivers for High-Accuracy Multipath-Assisted Indoor Positioning [C] //IEEE ICC Workshop on Advances in Network Localization and Navigation(ANLN). IEEE, 2017.
- [18] 曾庆化, 王敬贤, 孟骞, 等. 基于 UWB 优化配置的室内行人导航方法 [J]. 中国惯性技术学报, 2017(2) : 52-57.
- [19] Huang G B, Zhu Q Y, Siew C K. Extreme Learning Machine: Theory and Applications [J]. Neurocomputing, 2006, 70(1-3) : 489-501.
- [20] Mocanu E, Nguyen P, Gibescu M, et al. Deep Learning for Estimating Building Energy Consumption [J]. Sustainable Energy, Grids and Networks, 2016: S2352467716000163.
- [21] Huang G B, Zhu Q Y, Siew C K. Extreme Learning Machine: Theory and Applications [J]. Neurocomputing, 2006, 70(1-3) : 489-501.
- [22] Kennedy J, Eberhart R. Particle Swarm Optimization [C] //Proceedings of ICNN '95—International Conference on Neural Networks. IEEE, 1995.
- [23] 李伟, 郭红利, 乔凤娟, 等. 基于 PSO 的 ELM 集成学习算法研究 [J]. 齐鲁工业大学学报, 2018, 32(5) : 35-41.
- [24] 邓天民, 方芳, 岳云霞, 等. 基于 Elman 神经网络的 GNSS/INS 全域高精度定位方法 [J]. 计算机应用, 2019, 39(4) : 994-1000.
- [25] 赵妍, 乐燕芬, 施伟斌. 基于微粒群优化 LSSVM 的室内指纹定位算法 [J]. 软件导刊, 2019, 018(4) : 87-90, 94.
- [26] 宋宁佳, 崔英花. 基于 GA-GRNN 的 RFID 室内定位算法 [J]. 计算机工程, 2019, 45(11) : 298-302, 308.



缪希仁(1965—),男,1986年于北京航空航天大学获得学士学位,1989年于福州大学获得硕士学位,2000年于福州大学获得博士学位,现为福州大学教授,主要研究方向为电器及其系统智能化技术、电气设备在线监测与诊断, miaoxr@163.com;



江 灏(1986—),男,2008年于厦门大学获得学士学位,2011年于厦门大学获得硕士学位,2013年于厦门大学获得博士学位,2013-2015年新加坡南洋理工大学博士后研究员,现为福州大学副教授,主要研究方向为无线传感网络、室内定位技术、智能感知系统、光传感网络和机器学习, jiangh@fzu.edu.cn.